基于医学 X 光片预训练改进工业射线检测中的缺陷识别

于涵，李星杰 *，谢华生，李新月，侯春雨
中国机械科学研究总院沈阳铸造研究所有限公司，先进铸造技术国家重点实验室，辽宁中国

关键词：迁移学习；工业缺陷识别；医学 X 光片；数字射线成像

摘要

深度学习方法在焊缝、铸件等领域的工业射线检测缺陷识别中得到了广泛应用。无论采用何种深度学习模型，使用基于 ImageNet 预训练的模型以加速收敛、提高识别精度已成为标准配置。然而，自然图像领域与工业 X 光片之间存在显著差距，这引发了一个问题：是否存在比依赖 ImageNet 预训练更优的预训练方法？幸运的是，由于成像方式相同，医学 X 光片与工业 X 光片的相似度远高于自然图像。本文首先利用 CheXpert 数据集中的大量医学 X 光片训练一个预训练卷积神经网络（CNN）模型，随后将该模型应用于两种射线检测场景下的四项不同任务，验证其优势与泛化能力。最终，多数据集实验表明，该方法相比 ImageNet 预训练或从头训练带来了更显著的效果，缺陷分类的 F1 分数提升了 3.41%~13.72%，缺陷分割的平均交并比（mIoU）提升了 1.05%~6.58%。研究表明，基于医学 X 光片的预训练为工业缺陷识别的各类任务实现了无成本的性能提升。

1 引言

射线检测（RT）是五大常规无损检测（NDT）技术之一。由于射线检测能直观显示机械零部件内部缺陷的尺寸、分布和形状，其在工业场景中应用广泛，在部分关键领域甚至具有不可替代性。近年来，数字射线成像（DR）技术日趋成熟，成为射线检测领域的研究热点 [1-3]。数字射线成像技术的实现过程分为三步：1）X 射线管向被测物体发射射线能量；2）数字探测器阵列（DDA）采集射线能量与被测物体的相互作用结果；3）计算机将相互作用结果以图像形式展示。由此，数字射线成像技术检测效率高、成本低、污染小，为基于视觉的内部缺陷识别创造了条件 [4,5]。

机器视觉技术的发展使深度学习算法成为数字射线成像自动缺陷识别的主要手段。Mery 等人 [6] 建立了 GDXray 公共数据集，为 X 光片缺陷识别的计算机视觉算法研发提供支撑；Chang 等人 [7] 提出一种结合柱面投影的改进分割模型，增强了焊缝微小缺陷的识别能力；为解决焊缝 X 光片数据不平衡问题，有研究提出了名为 CECGAN 的生成对抗网络（GAN）模型 [8]；Tang 等人 [9] 利用双线性卷积神经网络（BCNN）提升铸件缺陷的分类能力；Du 等人 [10] 提出双流网络，实现了比 UNet[11] 更优的分割效果；于等人 [12] 提出深度与感受野自适应选择网络，实现了铸件 X 射线缺陷的端到端分割；Zheng 等人 [13] 提出 U 型显著性检测网络，用于轮胎缺陷分割。

上述方法均采用基于 ImageNet[14] 预训练的骨干网络进行特征提取。使用 ImageNet 预训练权重已被证实是跨各类图像识别任务进行迁移学习的有效方法。大量研究 [15-18] 表明，预训练卷积神经网络不仅能加速模型收敛，还能提升识别精度。当训练数据稀缺时，缺乏预训练权重可能导致模型无法收敛。预训练的优势源于卷积神经网络能从大量自然图像中学习到通用的特征表示。如表 1 和图 1 所示，工业 X 光片与自然图像的差异远大于其与医学 X 光片的差异，具体差异总结如下：

表 1 自然图像、医学 X 光片与工业 X 光片的主要差异

1. **色深**：受成像方式影响，自然图像为彩色，而 X 光片为单通道灰度图像，导致 ImageNet 预训练模型提取的颜色特征失效。

2. **透视畸变**：自然图像的透视畸变显著，而 X 光成像中被测物体与 X 射线源的距离基本一致，射线近乎平行地到达探测器，因此透视畸变通常轻微。

3. **语义信息**：每张自然图像均具有独特性，语义信息丰富；而人体组织与机械零部件的高度相似性导致 X 光片的相似度极高。

4. **判别信息**：自然图像识别通常通过识别清晰的全局主体实现，而医学 X 光片的病变和工业 X 光片的缺陷需通过检测局部异常和纹理变化识别。

5. **图像数量**：自然图像易获取且易标注，而医学和工业领域的数据集受专家经验限制，标注图像数量较少（从数十张到几十万张不等）。例如，ImageNet 包含约 120 万训练数据，CheXpert[22] 包含 22 万张胸部 X

光片，GDXray 包含 1.9 万张 X 光片。

6. **类别数量**：病变和缺陷的类别有限，通常不超过 100 类，而 ImageNet 包含 1000 个物体类别。

基于上述分析，自然图像与工业 X 光片领域间存在显著差距，这引发了一个问题：是否存在比自然图像预训练模型更优的方法？然而，现有研究主要聚焦于改进卷积神经网络的结构，忽略了预训练模型的潜在影响。因此，本文尝试通过构建更优的预训练模型，改进射线检测中的工业缺陷识别效果。本文的核心贡献如下：

1. 首次探索利用医学 X 光片的预训练权重实现工业缺陷识别无成本性能提升的可行性；
2. 将为医学 X 光片分析开发的预训练模型应用于焊缝和铸件两种射线检测场景下的四项具体任务（缺陷分类与分割），多组实验表明，基于医学 X 光片的预训练相比 ImageNet 预训练或从头训练带来了更显著的提升；
3. 开源本文的预训练模型，为射线检测领域的其他应用提供更优的预训练模型支撑。

2 相关工作

深度神经网络天然适用于迁移学习，“预训练 + 微调” 已成为深度学习模型的标准使用配置。Yosinski 等人 [15] 发现，“预训练 + 微调” 能提升模型的泛化性能，且特征的可迁移性随预训练任务与下游任务的领域距离增大而降低；He 等人 [16] 得出结论，ImageNet 预训练能在训练初期加速收敛；Kornblith 等人 [17] 证实，基于大数据集的预训练决定了下游任务的性能下限，且下游任务的训练数据越少，预训练的提升效果越显著；Dan 等人 [18] 表明，预训练能增强模型对噪声标签、数据不平衡和跨领域问题的鲁棒性。

鉴于自然图像与医学图像的显著差异，已有大量研究探索直接基于医学图像预训练是否能带来更优的性能提升。Raghu 等人 [19] 研究了 ImageNet 预训练在医学图像任务中的特性，发现其性能提升有限；Wen 等人 [20] 探究了医学预训练的特性及其在各类医学任务中的迁移效果，实验表明医学

预训练对分类任务效果更优，但对分割任务无明显提升；有研究整合多个 3D 医学数据集 [21] 并训练 3D 预训练卷积神经网络，显著提升了 CT 和 MRI 相关任务的性能。受上述研究启发，本文首次对工业缺陷识别中使用 ImageNet 迁移学习的必要性提出质疑，并尝试探索一种新型预训练方案。

3 提出的方法

本节详细描述本文的处理流程（见图 2），该方法主要分为两个阶段：首先，在多标签分类框架下利用医学 X 光片训练骨干网络；随后，将预训练权重应用于工业缺陷分类和分割任务，提升任务性能。

3.1 预训练阶段

本文的研究动机是利用医学 X 光片训练高性能的卷积神经网络骨干，将其作为预训练权重，提升训练数据不足的工业场景下的缺陷识别任务性能。预训练数据集需包含足够的训练数据和类别，以保证图像的多样性，使网络学习到具有判别性的特征。因此，本文选择 CheXpert[22] 作为预训练数据集，该数据集包含 65240 名患者的 224316 张胸部 X 光片，涵盖 14 个类别：无异常、心纵隔增大、心脏肥大、肺不透明度、肺部病变、水肿、实变肺炎、肺不张气胸、胸腔积液、其他胸膜病变、骨折、辅助装置。每张 X 光片可能同时属于多个类别，因此将其视为多标签分类问题。

选择 ResNet50[23] 作为骨干网络的基础框架，因其是应用最广泛的卷积神经网络架构。针对 X 光片的单通道特性，首先将其第一个卷积层的通道数从 3 改为 1。骨干网络将图像转换为特征图，特征图通过全局平均池化（GAP）和全连接层转换为 14 维向量，再经逐元素 Sigmoid 激活函数得到最终输出，输出的每个维度代表对应类别的存在概率。因此，采用二元交叉熵（BCE）损失训练该网络：

$L_{bce} = -\sum_{i=1}^{14} \left[y_i \log p\left(y_i\right) + \left(1 - y_i\right) \log \left(1 - p\left(y_i\right)\right) \right]$

其中，$p(y_i)$ 为图像属于第 i 类的预测概率，$y_i \in \{0, 1\}$ 为真实标签，$y_i = 1$ 表示该图像包含第 i 类病变。受图像清晰度限制，数据集中部分图像无法由专家判断是否属于某一类别，本文将此类不确定样本视为正样本。

按照官方划分方式，每个训练轮次计算验证集的损失，保存验证损失最低的网络权重，用于下游任务。

3.2 迁移阶段

得到预训练权重后，将其应用于射线检测的缺陷识别任务。缺陷分类和分割是基于视觉的缺陷识别最常用的两种方式：

1. **缺陷分类**：旨在判断图像中是否存在缺陷，与预训练阶段的任务相似。直接将预训练权重作为骨干网络的初始权重，仅在骨干网络后接入全连接层和 Softmax 层，以减少干扰。预训练权重提取的特征图被转换为缺陷存在的概率。

2. **缺陷分割**：目标是实现缺陷的精确定位、面积测量和深度估计。UNet 已成为训练数据不足的图像分割任务中最常用的模型之一。原始 UNet 采用 VGG 作为编码器，提取输入图像的多尺度特征。本文将预训练的 ResNet50 替换 VGG 作为编码器，解码器采用随机初始化。针对缺陷分割任务中的数据不平衡问题，联合使用像素级二元交叉熵损失和 Dice 损失对网络进行微调。

值得注意的是，由于图像领域间存在显著差异，上述两项任务均不冻结预训练权重，而是将其作为网络权重在微调过程中的可更新初始值。

随后，在两种射线检测场景的四项任务中，验证预训练权重的优势和泛化能力。

4 实验设置

4.1 数据集与预处理

射线检测是焊缝和铸件无损检测的最重要手段，本文选择 GDXray-焊缝 [6] 和 Zju-铸件 [10] 数据集，与基于自然图像的预训练权重进行对比实验。

GDXray-焊缝数据集原始包含 10 张焊缝 X 光片及其缺陷的二值标注，图像尺寸为 366×3512 至 1091×4953。由于图像尺寸过大，对原始 X 光片和

标注图像进行同步裁剪，得到 316 个小图像块。根据标注图像可快速区分图像块是否存在缺陷，由此构建缺陷分类任务（区分正常和缺陷图像块）；缺陷图像块及其标注则用于缺陷分割任务。

Zju-铸件数据集收集了 3148 张铸件 X 光片及六种汽车零部件的标签，所有图像尺寸均为 1000×1000，采用上述相同方法进行处理。图 3 和表 2 展示了两个数据集的详细信息。

上述两个数据集和四项任务不仅覆盖了射线检测的典型场景，还验证了模型在小样本和相对充足样本下的性能。

表 2 不同任务的实现细节

4.2 实现细节

本研究的计算硬件配置为：i9-9920X 处理器、64 GB 内存、24 GB 显存的 TITAN RTX 显卡；所有模型均基于 PyTorch 框架开发；ImageNet 预训练权重来自 TorchVision 库。缺陷分类任务采用水平和垂直翻转作为数据增强方式；分割任务则增加了随机缩放、亮度调整和旋转等变换。各任务的关键实现信息见表 2。

4.3 评价指标

缺陷分类任务采用**准确率（Accuracy）**和 **F1 分数**进行评价，其中 TP、FN 分别为正确和错误识别的缺陷图像数量，TN、FP 分别为正确和错误识别的正常图像数量，计算公式如下：

$Accuracy = \frac{TP+TN}{TP+TN+FN+FP}$

$Precision = \frac{TP}{TP+FP}$

$Recall = \frac{TP}{TP+FN}$

$F1 = \frac{2\times Precision\times Recall}{Precision+Recall}$

缺陷分割任务采用**精确率（Precision）**、**召回率（Recall）**和**平均交并比（mIoU）**进行评价，其中 TP、FN 分别为正确预测为缺陷和错误预测为非缺陷的缺陷像素数量，FP、TN 分别为错误预测为缺陷和正确预测为非缺陷

的非缺陷像素数量，mIoU 计算公式如下：
$mIoU = \frac{1}{2}\left(\frac{TP}{TP+FP+FN} + \frac{TN}{TN+FP+FN}\right)$

5 实验结果

5.1 与其他权重初始化方法的对比

本节通过在四项工业缺陷识别任务中测试预训练骨干网络的性能，验证其可迁移能力。

首先在缺陷分类任务中，将本文方法与随机初始化和 ImageNet 预训练进行对比。如表 3 所示，随机初始化的模型在两个数据集中的性能均最差，而基于医学 X 光片预训练的权重显著优于另外两种初始化方法。相比随机初始化和 ImageNet 预训练，本文方法在 GDXray-焊缝数据集的 F1 分数分别提升了 13.72% 和 3.41%。由于 Zju-铸件数据集的训练样本更多，本文方法的提升效果不如 GDXray-焊缝数据集显著，但相比 ImageNet 预训练仍提升了约 2.49%。

表 3 缺陷分类任务中不同权重初始化方法的定量对比

图 4 可视化了两个数据集的代表性分割结果，直观可见，即使在低对比度区域，本文方法的分割结果也具有更精确的边界。如表 4 所示，基于医学 X 光片的预训练同样对缺陷分割任务有益，与分类任务类似，本文方法在 GDXray-焊缝数据集的 mIoU 提升了 6.58%，高于 Zju-铸件数据集的 1.05%。整体而言，预训练权重在分类任务中的提升效果优于分割任务，原因在于分割模型的骨干网络参数相对较少，且解码器的影响存在一定限制。

表 4 缺陷分割任务中不同权重初始化方法的定量对比

5.2 训练数据量的影响

训练数据量对深度学习模型的性能影响显著。在缺陷识别领域，往往难以获取充足的训练数据，这要求模型具备强大的特征提取能力，能表征样本的本质差异。若本文的预训练模型在小样本下仍保持优势，则表明其具有更优的特征提取能力。为验证这一点，使用 25%、50%、75% 和 100% 的 Zju-铸件

训练数据训练三种不同预训练权重的模型，验证集和测试集保持不变以保证对比的公平性。

如图 5 所示，使用全部训练数据时，分类和分割任务均取得最高的 F1 分数和 mIoU 值；训练数据量减少时，模型因过拟合导致性能下降。仅使用 25% 的训练数据时，本文方法的缺陷分类 F1 分数达到 0.8327，比 ImageNet 预训练高 20.88%，而随机初始化的模型甚至无法收敛；随着训练数据量增加，性能差距逐渐缩小，使用 100% 训练数据时，本文方法仍提升了 2.49%。与分类任务一致，训练数据不足时，本文方法对缺陷分割任务的提升效果更显著。上述实验表明，基于医学 X 光片的预训练模型对训练数据量的依赖性更低。

5.3 训练时间的影响

本节探索训练时间对模型性能的影响，收敛速度也是模型的重要指标，若预训练模型能加速收敛，说明网络从更优的初始值开始训练。使用 GDXray-焊缝和 Zju-铸件数据集进行测试，记录不同训练轮次或迭代次数下的模型性能（见图 6）。由于数据集规模不同，GDXray-焊缝数据集以训练轮次为时间尺度，Zju-铸件数据集以迭代次数为时间尺度。

如图 6 所示，在所有任务中，基于医学 X 光片的预训练模型收敛速度最快，其次是 ImageNet 预训练模型。在 GDXray-焊缝数据集中，仅训练 5 个轮次，本文方法的 F1 分数达到 0.86，比 ImageNet 预训练的 0.8179 高 4.2%，比随机初始化的 0.6909 高 24.47%；随着训练的进行，本文方法仍保持最高的精度，但性能差距缩小至 3.2%~13.7%。分割任务中出现类似现象：训练初期模型未收敛，mIoU 值为无效值（NaN），但本文方法从第 2 个轮次开始收敛，ImageNet 预训练模型从第 6 个轮次开始收敛，随机初始化模型从第 8 个轮次开始收敛；所有模型收敛后，本文方法的性能仍为最优。在 Zju-铸件数据集中，仅展示训练初期的结果（提升效果最显著），如图 6(c)(d) 所示，基于医学 X 光片的预训练模型同样收敛速度更快，证明该方法在工业射线检测领域具有良好的泛化性。

5.4 对超参数的敏感性

批次大小和学习率是神经网络训练中的关键超参数。为评估预训练权重对这些超参数的敏感性，在焊缝缺陷分类任务的训练过程中，测试了批次大小和学习率的多种组合。如图 7 所示，本文方法优于另外两种初始化方法，且对超参数具有较高的稳定性。

5.5 特征可视化

采用 t-SNE 方法 [24] 可视化 ImageNet 预训练和医学 X 光片预训练模型提取的特征分布（见图 8），每个点代表 GDXray-焊缝或 Zju-铸件的一个样本，红色为缺陷样本，绿色为正常样本。可见，本文方法提取的所有特征在嵌入空间中的聚类效果优于 ImageNet 预训练，且在 GDXray-焊缝数据集中的聚类效果更优，这与表 3 的结果一致。

此外，采用 Grad-CAM 方法 [25] 绘制不同模型的类别激活图，该方法是一种深度学习可解释性方法，通过计算可微输出的梯度并进行空间池化确定神经元的重要性权重，再利用该权重融合激活图，识别模型关注的关键特征。如图 9 所示，基于医学 X 光片的预训练模型更关注缺陷区域。

5.6 不同骨干网络的鲁棒性

为进一步验证本文方法在不同骨干网络中的鲁棒性，将实验扩展至另外两种架构：VGG16[26] 和 ViT[27]。选择这两种模型具有明确的目的性，分别代表不同的深度学习方法：VGG16 作为传统简单卷积神经网络的代表，反映传统架构在本文方法下的性能；ViT 作为深度学习的最新成果，利用自注意力机制建模长距离依赖关系。对于分割模型，进一步引入另一种广泛使用的 Deeplabv3+[28] 模型，与 UNet 形成互补，验证本文方法的适应性。

在缺陷分类任务中，表 5 展示了 GDXray-焊缝数据集中不同骨干网络在 ImageNet 预训练和本文方法下的定量对比结果，表明本文方法在所有架构中均优于 ImageNet 预训练模型。分割任务中得出类似结论，表 6 展示了 Zju-铸件数据集中不同分割模型和骨干网络在 mIoU 指标下的对比结果，表明本文方法能提升所有模型和骨干网络的分割性能。例如，ViT 骨干网络在

UNet 中的 mIoU 从 63.46 提升至 68.24，在 Deeplabv3+ 中从 59.24 提升至 61.31。上述结果证明，本文方法在不同类型的骨干网络中均具有鲁棒性，能有效提升缺陷识别能力。

表 5 不同骨干网络在缺陷分类任务中的定量对比

表 6 不同分割模型和骨干网络在 mIoU 指标下的定量对比

6 局限性

尽管本文的研究为工业射线检测缺陷识别领域做出了贡献，但仍存在一些局限性：第一，研究仅覆盖了两种射线检测场景，无法完全代表工业 X 光片的多样性；第二，基于医学 X 光片的预训练虽被证实有效，但并非工业 X 光片应用的最优预训练方式；第三，研究可能存在潜在偏差，如数据集和模型选择的偏差。针对上述局限性，未来的研究可聚焦于探索其他预训练方法，以实现工业缺陷识别性能的进一步提升。

7 结论

本文对工业射线检测缺陷识别任务中使用 ImageNet 预训练权重的有效性和合理性提出质疑。通过全面分析自然图像、医学 X 光片和工业 X 光片之间的差异，探索了利用医学 X 光片预训练权重实现工业缺陷识别无成本性能提升的可行性。在 CheXpert 数据集的多标签分类框架下训练得到预训练骨干网络，并将其迁移至缺陷分类和分割任务。多组实验表明，基于医学 X 光片的预训练相比 ImageNet 预训练或从头训练带来了更显著的性能提升，在训练数据不足时效果尤为明显；此外，预训练权重在分类任务中的提升效果优于分割任务。

未来，计划研究基于工业 X 光片的自监督学习方法，以进一步提升特征学习能力。

作者贡献声明

于涵：软件设计、方法学、概念提出；
李星杰：项目管理、资金筹措；
谢华生：论文审阅与修改、可视化、调研、数据整理；
李新月：软件设计；
侯春雨：验证、概念提出。

利益冲突声明

作者声明，不存在可能影响本研究成果的已知财务利益冲突或个人关系。

致谢

本研究得到辽宁省自然科学联合基金（2023-MSLH-330）、辽宁省科技联合计划（2023JH2/101700038）资助。

数据可用性

数据可根据请求提供。